Convolutional Neural Network (2)

Jehyuk Lee

Department of AI, Big Data & Management

Kookmin University



Contents

Review

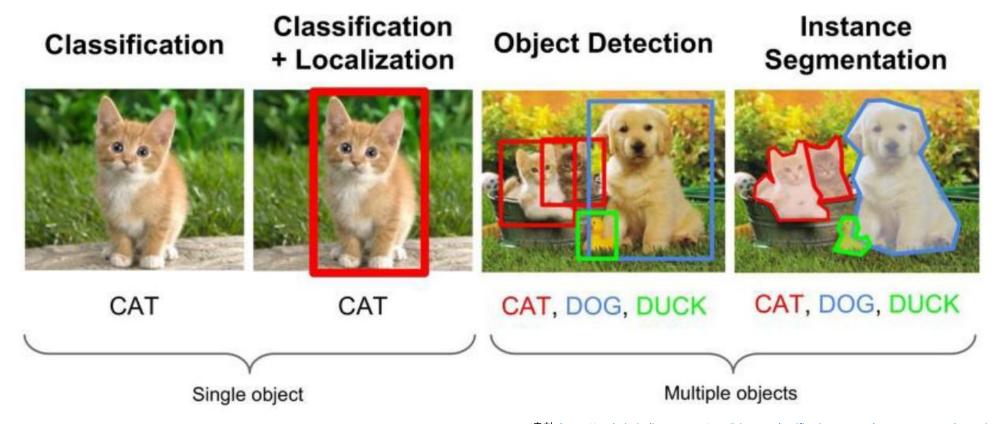
- Advanced CNN model
 - AlexNet, VGGNet, GoogLeNet, ResNet, DenseNet
- Class Activation Map (CAM)

Transfer Learning

1. Review

Convolutional Neural Network

- 합성곱 신경망(Convolutional Neural Network)
 - Convolutional 연산을 수행하는 Neural Network
 - 이미지로부터 필요한 특징을 스스로 학습하는 능력을 갖춤

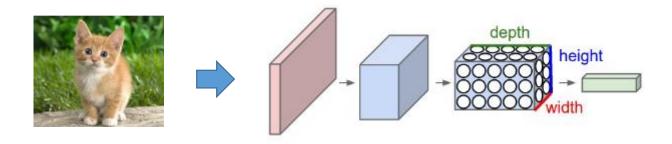


(출처: https://analyticsindiamag.com/top-5-image-classification-research-papers-every-data-scientist-should-know/

Convolutional Neural Network

• Convolutional Neural Network는 이런 한계점을 극복

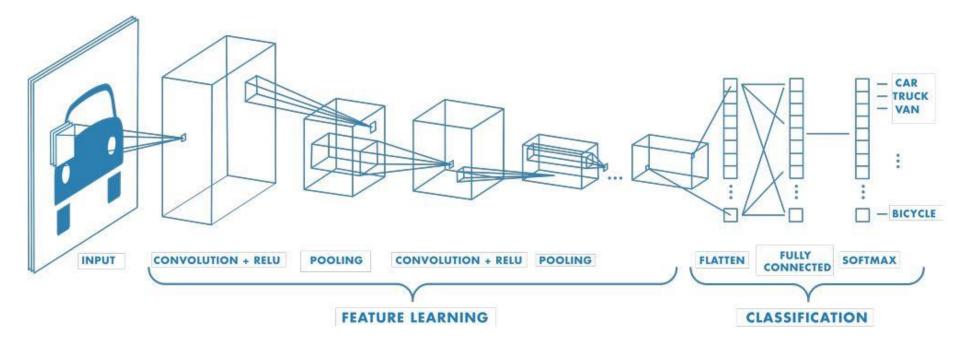
- CNN은 이미지의 형상 정보를 유지
 - CNN은 일반적인 FFNN과 달리 3차원으로 뉴런이 배열되어 있다.
 - Width, Height, Depth
 - (요건 Convolutional Layer를 다룰 때 좀 더 자세히 알아보자)



CNN Structure

Convolutional Neural Network Structure Overview

- CNN은 일반적으로 다음과 같은 layer들로 구성되어 있음
 - Convolutional Layer: Input의 일부 region과 filter간의 convolution연산을 수행하는 layer
 - Activation Layer: Convolution 연산을 수행한 결과에 대해 element-wise activation 연산 수행
 - Pooling Layer: 차원별로 Downsampling하는 layer



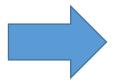
(출처: https://kr.mathworks.com/discovery/convolutional-neural-network-matlab.html)

Image Representation

• 이미지를 다음과 같이 컴퓨터에게 인식할 수 있음

- 이미지는 다음과 같이 표현 가능
 - RGB 3개의 channel
 - 3차원의 Tensor (RGB)





```
array([[136, 131, 128, ..., 149, 156, 159],

[ 54, 50, 49, ..., 80, 84, 87],

[ 40, 38, 39, ..., 70, 74, 76],

...,

[179, 174, 173, ..., 187, 189, 192],

[170, 169, 170, ..., 191, 192, 193],

[165, 166, 169, ..., 195, 195, 195]], dtype=uint8)
```

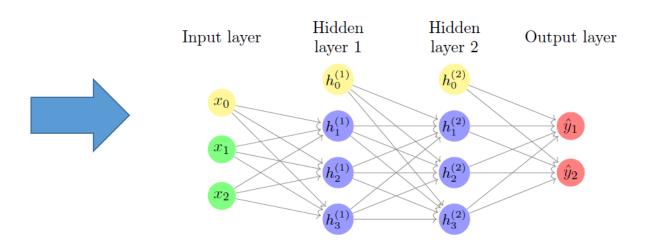
```
array([[155, 148, 141, ..., 136, 139, 142],
[ 71, 65, 60, ..., 63, 67, 70],
[ 54, 51, 48, ..., 50, 54, 54],
...,
[151, 146, 145, ..., 165, 167, 170],
[144, 143, 144, ..., 172, 173, 174],
[139, 140, 143, ..., 177, 177, 177]], dtype=uint8)
```

(출처: https://analyticsindiamag.com/top-5-image-classification-research-papers-every-data-scientist-should-know/)

• 가장 간단한 방법은... 각 픽셀 별로 weight 생성

- 각 픽셀별로 weight생성
- 그러나 엄청나게 많은 weight가 필요
 - 아래 이미지 데이터의 크기는 174*203
 - 필요한 weight의 수 : 174 * 203 * 3* (hidden layer의 뉴런 수) = 105K * (hidden layer 뉴런 수)

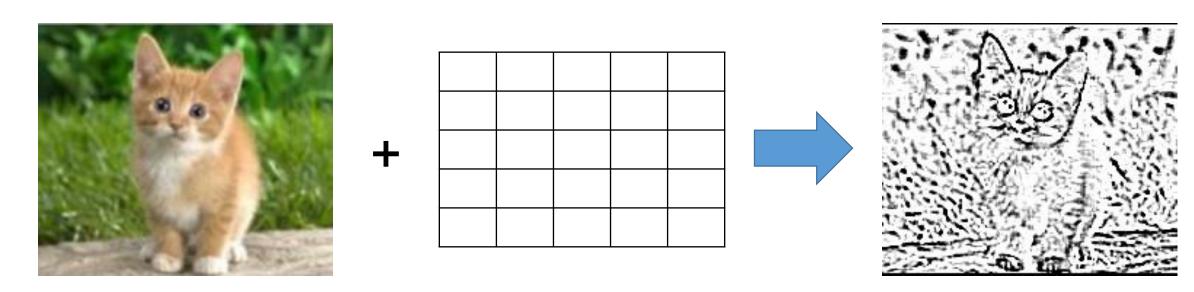




(출처: https://analyticsindiamag.com/top-5-image-classification-research-papers-every-data-scientist-should-know/, https://www.romsoc.eu/artificial-neural-network-and-data-driven-techniques-scientific-computing-in-the-era-of-emerging-technologies/)

Image Convolution

- 특정 속성을 탐지하는데 사용하는 tensor
- Filter, Kernel이라고 부르기도 함
- 이 Filter를 이미지의 각 region별로 적용 (Parameter sharing)
- 예시: edge detection



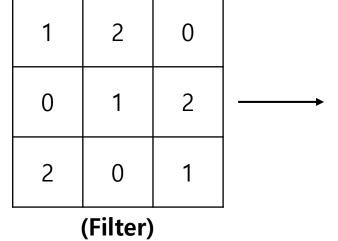
(출처: https://analyticsindiamag.com/top-5-image-classification-research-papers-every-data-scientist-should-know/, https://www.romsoc.eu/artificial-neural-network-and-data-driven-techniques-scientific-computing-in-the-era-of-emerging-technologies/)

Convolution Operation (in Image)

- 입력 데이터와 필터 간의 연산
 - 필터의 윈도우(window)를 일정 간격으로 이동하면서 입력 데이터에 적용
 - 입력데이터와 필터 간의 element-wise multiply연산 후 add

1	2	3	4	0
0	1	2	3	4
4	0	1	2	3
3	4	0	1	2
4	0	1	2	3





 19
 18
 27

 10
 19
 18

 17
 6
 15

(11100

(Output)

(Input Data)

$$1 * 1 + 2 * 2 + 3 * 0 + 0 * 0 + 1 * 1 + 2 * 2 + 1 * 2 + 2 * 0 + 3 * 1 = 15$$

Convolution Operation (in Image)

- Padding
 - Convolutional을 수행하기 전에 데이터 주변을 특정 값(ex: 0)으로 채우기도 함 → Padding
 - 주로 출력 크기를 조정할 목적으로 사용

1	2	3
0	1	2
4	0	1

(Before Padding)

0	0	0	0	0
0	1	2	3	0
0	0	1	2	0
0	4	0	1	0
0	0	0	0	0

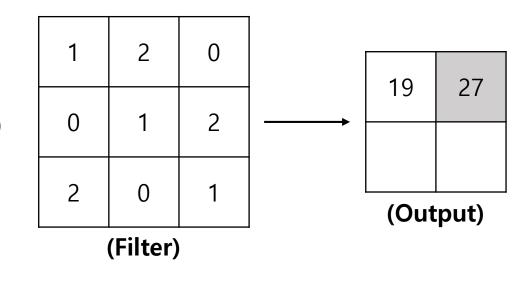
(After Padding)

Convolution Operation (in Image)

- Stride
 - 예시: Stride=2 (input data에서 2만큼 이동하여 filter를 적용)

(*)

1	2	3	4	0
0	1	2	3	4
4	0	1	2	3
3	4	0	1	2
4	0	1	2	3



(Input Data)

Convolution Operation (in Image)

- Convolution 연산 결과의 shape 예측하기
 - 입력 데이터의 크기: (*H*, *W*)
 - 필터의 크기: (FH, FW)
 - 패딩의 크기: P
 - 스트라이드: S
 - 출력 데이터의 크기 (OH, OW)는 다음과 같음

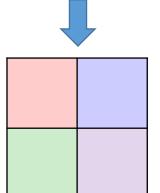
$$OH = 1 + \frac{(H + 2P - FH)}{S}$$

$$OW = 1 + \frac{(W + 2P - FW)}{S}$$

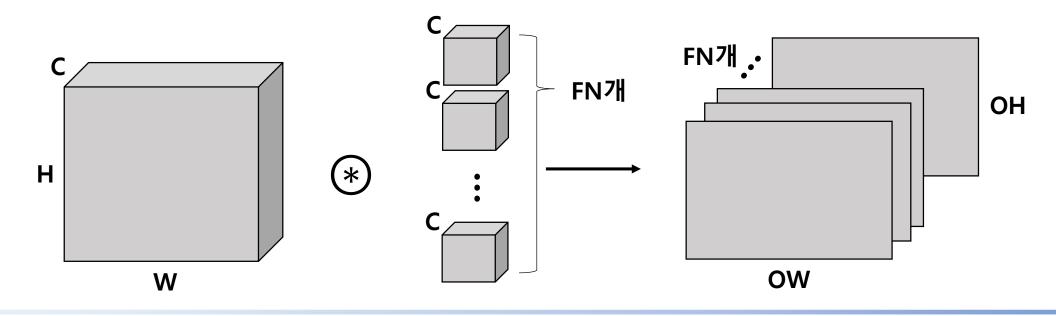
0	0	0	0	0
0	1	2	3	0
0	0	1	2	0
0	4	0	1	0
0	0	0	0	0

$$(H, W) = (3, 3)$$

 $(FH, FW) = (3, 3)$
 $P = 1, S = 2$



- Convolution Operation (in Image)
 - 이미지는 3차원 블록
 - (C, H, W) = (Channel, Height, Width)
 - Filter도 사실은 3차원 블록
 - (C, FH, FW) = (Channel, Filter Height, Filter Width)
 - 예시: 3차원 이미지와 3차원 Filter로부터 FN개의 feature map생성

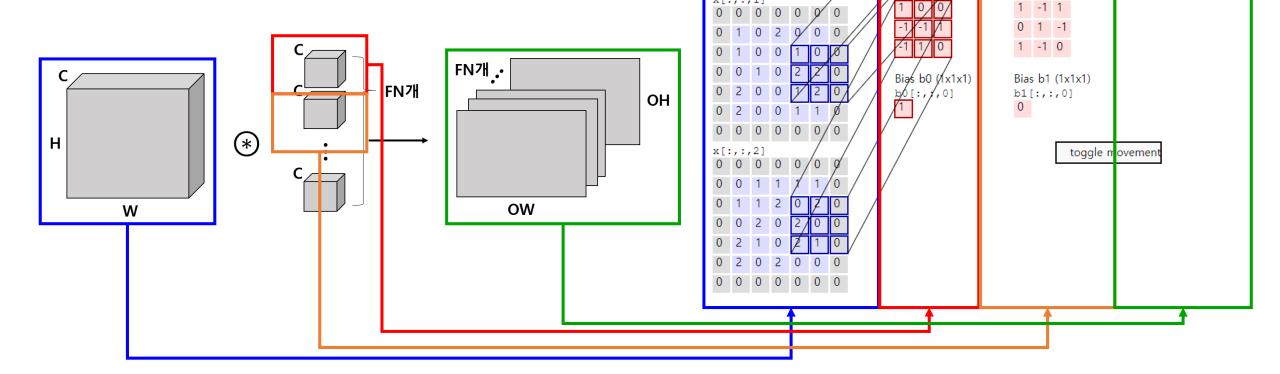


Convolution Operation (in Image)

- 이미지는 3차원 블록

2023-10-06

- Filter도 사실은 3차원 블록



(출처: https://cs231n.github.io/convolutional-networks/#architectures)

Output Volume (3x3x2)

0[:,:,0]

3 0 2

-2 -3 6

0[:,:,1]

-4 -7 -4 -3 -4 -5 0 4 1

Input Volume (+pad 1) (7x7x3)

0 0 0 0 0 0

0 1 2 2 2 1 0

0 1 2 2 2 2

0 0 0 0 0 0 0

x[:,:,0]

0 0 0 0

Filter W0 (3x3x3)

w0[:,:,0]

Filter W1 (3x3x3)

w1[:,:,0]

0 1 1

-1 -1 0

0 0 0

w1[:,:,1]

0 0 0

Convolution Operation (in Image)

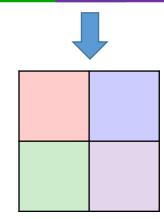
- Convolution 연산 결과의 3차원 shape 예측하기
 - 입력 데이터의 크기: (*C*, *H*, *W*)
 - 필터의 크기: (C,FH,FW)
 - 패딩의 크기: P
 - 스트라이드: S
 - 필터 수: FN
 - 출력 데이터의 크기 (OC, OH, OW)는 다음과 같음

$$OC = FN$$

$$OH = 1 + \frac{(H + 2P - FH)}{S}$$

$$OW = 1 + \frac{(W + 2P - FW)}{S}$$

0	0	0	0	0
0	1	2	3	0
0	0	1	2	0
0	4	0	1	0
0	0	0	0	0

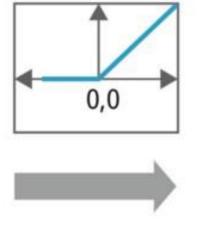


Activation Function

- Convolution 연산 결과의 비선형 변환을 수행
- (대부분 ReLU를 사용)

20 35 15 -10 -110 25 100 18 20 -15 25 -10 75 23 101 18

Transfer Function



15	20	0	35
18	0	25	100
20	0	25	0
101	75	18	23

(출처: https://medium.com/data-science-group-iitr/building-a-convolutional-neural-network-in-python-with-tensorflow-d251c3ca8117)

Pooling Layer

Pooling

- 가로, 세로 방향의 공간을 줄이는 연산
 - 일정 영역의 정보를 축약하는 역할
 - 네트워크의 파라미터의 개수를 줄여 연산 수를 줄임 > 모델의 복잡성 감소 > 오버피팅 방지
 - 예시: Max Pooling with 2 × 2 filters with stride 2

1	2	3	4			
0	1	2	3		2	4
4	0	1	2		4	2
3	4	0	1	·		

Pooling Layer

Pooling

- Pooling 연산 결과의 shape 예측하기

- 입력 데이터의 크기: (C,H,W)
- 필터의 크기: (C,FH,FW)
- 공간 확장: F
- 스트라이드: S
- 출력 데이터의 크기 (OC, OH, OW)는 다음과 같음

$$OC = C$$

$$OH = 1 + \frac{(H - FH)}{S}$$

$$OW = 1 + \frac{(W - FW)}{S}$$

1	2	3	4
0	1	2	3
4	0	1	2
3	4	0	1

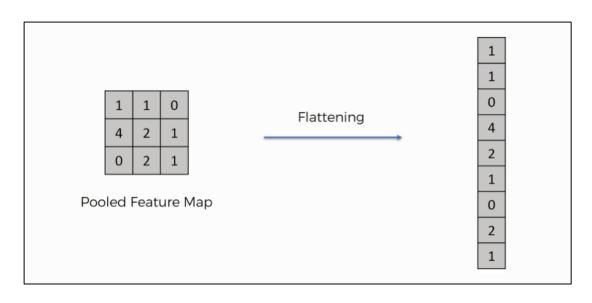


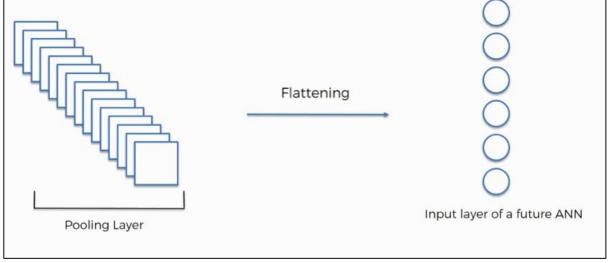
2	4
4	2

Fully-Connected Layer

Fully Connected Layer

- Flatten
 - 2차원/3차원의 Matrix/Tensor구조를 1차원 vector로 변환
- Input for Fully-connected layer
 - Convolutional-Pooling Layers의 연산 결과를 1차원 vector로 변환
 - 변환한 vector를 Fully-connected layer의 input으로





(출처: https://www.superdatascience.com/blogs/convolutional-neural-networks-cnn-step-3-flattening)

2. Advanced CNN model

ImageNet

- 천 가지 범주에서 뽑은 약 1천 4백만 장의 이미지들로 이루어진 거대한 데이터 베이스
- 이미지 부류가 아주 다양해서, 일상생활에서 볼 수 있는 대부분의 이미지를 포함
- ImageNet Large Scale Visual Recognition Challenge(ILSVRC)에서 이 데이터를 사용
 - Computer Vision 분야에서 권위 있는 Challenge



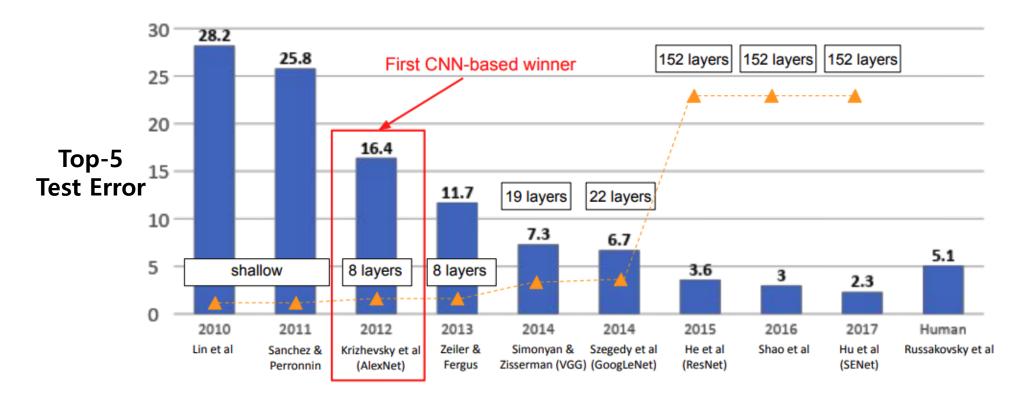
IMAGENET DATA BASE

(출처: https://supermemi.tistory.com/m/10)

• CNN이 본격적으로 사용된 건 생각보다 최근의 일

- Top-5 Error: 모델이 예측한 최상위 5개 범주 가운데 정답이 없는 경우의 오류율

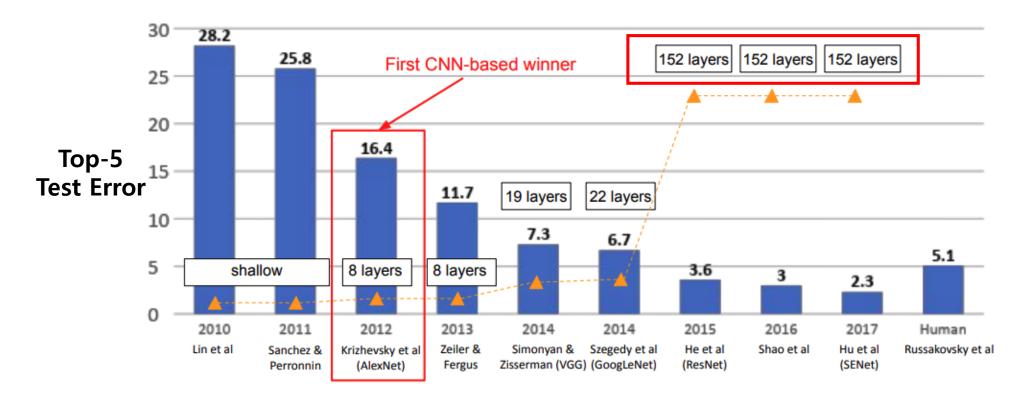
ImageNet Large Scale Visual Recognition Challenge (ILSVRC) winners



(출처: http://cs231n.stanford.edu/slides/2022/lecture_6_jiajun.pdf)

- CNN에서 layer가 많아질수록 이미지 분류 성능이 증가하는 추세
 - 심지어, 최근에는 효율적으로 연산(Operation수 감소), 정확한 모델 구조 등장

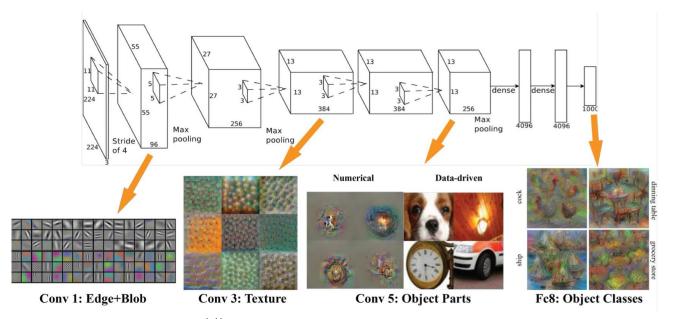
ImageNet Large Scale Visual Recognition Challenge (ILSVRC) winners



(출처: http://cs231n.stanford.edu/slides/2022/lecture_6_jiajun.pdf)

Case 1: AlexNet

- 제프리 힌튼 교수팀에서 최초로 CNN을 ImageNet에 적용
- 주요 구조
 - Conv, Max-Pooling, dropout layer 5개
 - Fully-connected layer 3개
 - Activation Function: ReLU

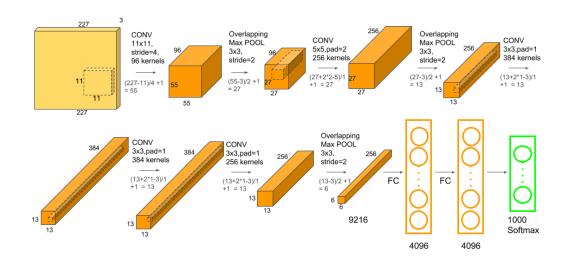




(출처: https://en.wikipedia.org/wiki/AlexNet)

Case 1: AlexNet

- 제프리 힌튼 교수팀에서 최초로 CNN을 ImageNet에 적용
- 특징
 - Input Size: 224*224
 - 초기 단계에서는 large filter size & stride
 - 상위 단계에서는 smaller size
 - # of Parameter: 60 Million

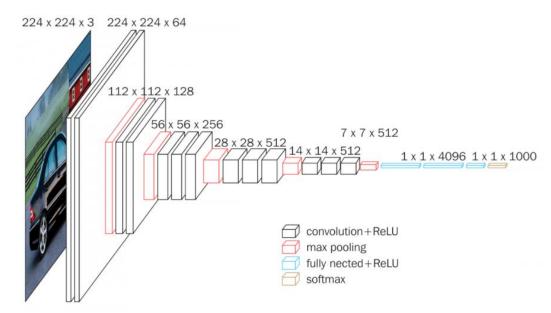




(출처: https://wikidocs.net/164787, https://en.wikipedia.org/wiki/AlexNet)

Case 2: VGGNet

- A. Zisserman, K. Simonyan이 제안
- 단순하지만 깊은 구조
 - 3*3 convolution with stride 1
 - 2*2 max pooling
- # of Parameter: 138 Million

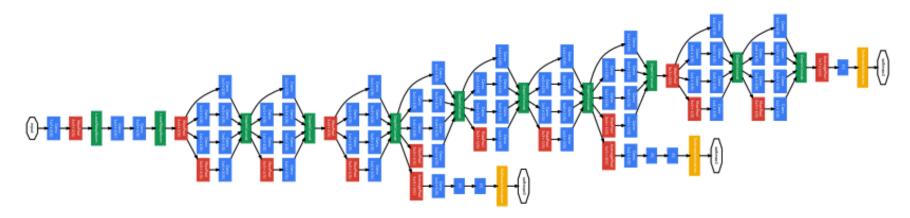




(출처: https://wikidocs.net/164796)

Case 3: GoogLeNet

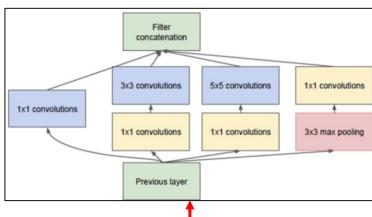
- Szegedy et al.이 제안
- 특징
 - 22 Layers
 - No fully connected layers
 - # of Parameters: 5 Million
 - 12x less than AlexNet(60M)
 - 27 times less than VGG-16(138M)

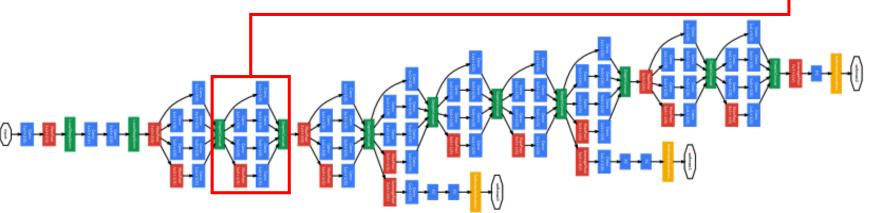


(출村: Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... & Rabinovich, A. (2015). Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1-9).)

Case 3: GoogLeNet

- 핵심은 Inception Module
 - 한 입력 image에 한종류의 filter만 적용해야 하나?
 - 뭘 좋아할지 몰라서 다 준비해봤어
 - 1*1 convolution (이 녀석은 뭘까요?)
 - 3*3 convolution
 - 5*5 convolution
 - 3*3 max pooling

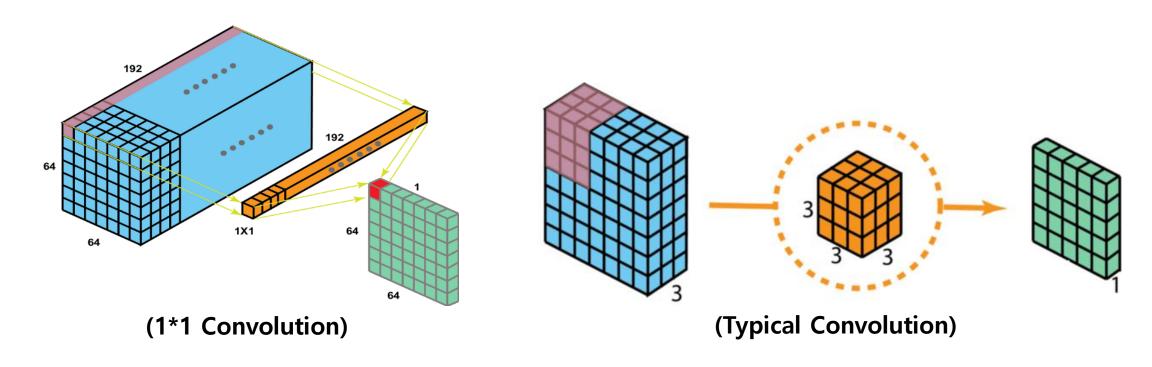




(출村: Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... & Rabinovich, A. (2015). Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1-9).)

Case 3: GoogLeNet

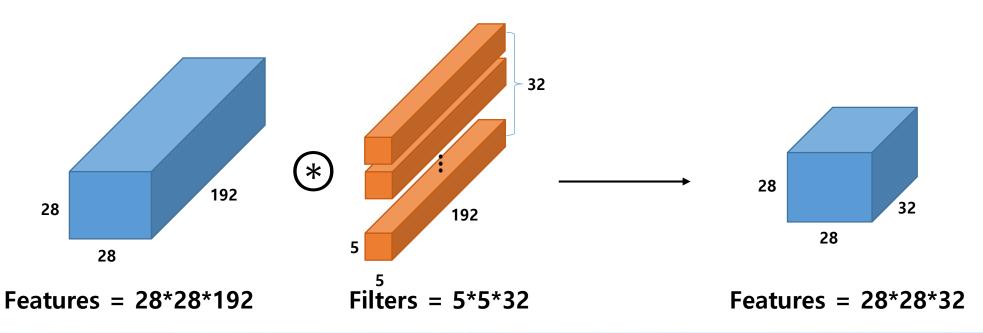
- 1*1 Convolution
 - Feature map의 depth를 감소시켜 연산량 줄이는 효과



(출처: https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

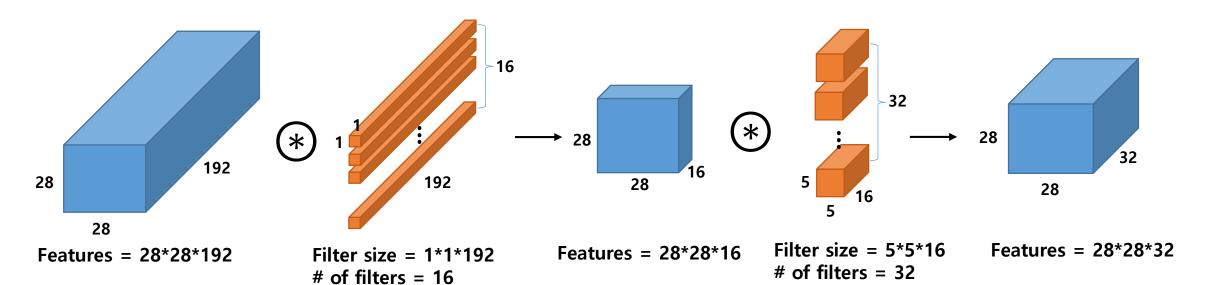
Case 3: GoogLeNet

- Without 1*1 Convolution
 - 예시: (height, width, channel) = (28,28,192)에서 5*5 convolution수행 (filter수는 32개)
 - 연산량
 - -(28*28*32)*(5*5*192) = 120M
 - (한 channel의 feature마다 필요한 conv횟수) * (한 conv마다 필요한 연산 수)



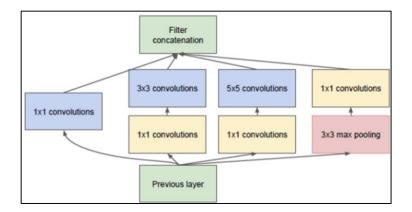
Case 3: GoogLeNet

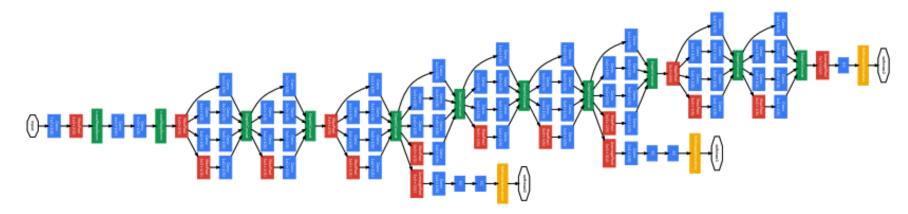
- With 1*1 Convolution
 - 예시
 - 1. (height, width, channel) = (28,28,192)에서 1*1 convolution수행 (filter수는 16개)
 - 2. (height, width, channel) = (28,28,,16)에서 5*5 convolution수행 (filter수는 32개)
 - 연산량
 - -(28*28*16)*(1*1*192)+(28*28*32)*(5*5*16)=2.4M+10M=12.4M<<120M



Case 3: GoogLeNet

- Inception 모듈
 - 1*1 convolution
 - 3*3 convolution
 - 5*5 convolution
 - 3*3 max pooling





→ 뭐 하러 모듈을 이렇게 복잡하게 만들었을까요? 그리고 얘는 왜 성능이 좋을까요?

(출처: Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... & Rabinovich, A. (2015). Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1-9).)

Case 3: GoogLeNet

- 이미지에서 물체의 크기는 상당히 큰 편차가 있습니다
- 정보의 위치가 다양하기 때문에 conv연산에 적합한 필터 크기 선정이 어려움
 - Filter size가 크면 전역적으로 배포되는 정보에 선호됨
 - Fitler size가 작으면 지역적으로 배포되는 정보에 선호됨
- 또한, 깊을수록 gradient vanishing문제 발생 → 깊이가 다가 아니다!!

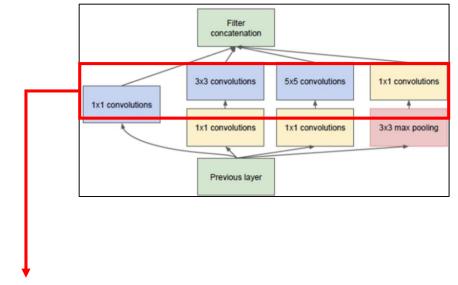






Case 3: GoogLeNet

- Inception 모듈
 - 1*1 convolution
 - 3*3 convolution
 - 5*5 convolution
 - 3*3 max pooling



- Filter Concatenation은 filter 수 방향으로 이뤄집니다.
 - 예시: 각 Conv의 결과가 (28*28*50) > Filter concatenation 결과는 (28*28*200)

Case 4: ResNet

- Kaiming He et al.이 제안
- 특징
 - 152 Layers
 - Residual Learning 개념 도입
 - Image Classification을 사람보다 더 높은 성능으로 수행
 - 다양한 대회 1위
 - ILSVRC 2015 Classification
 - ImageNet Detection
 - ImageNet Localization
 - COCO detection
 - COCO segmentation

What is COCO?



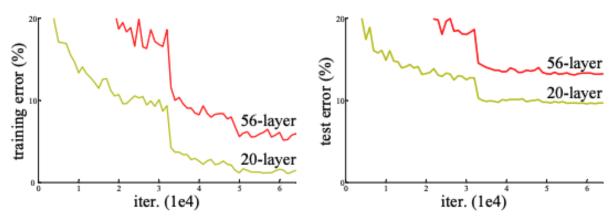
COCO is a large-scale object detection, segmentation, and captioning dataset. COCO has several features:

- Object segmentation
- ✓ Recognition in context
- Superpixel stuff segmentation
- 330K images (>200K labeled)
- 1.5 million object instances
- ◆ 80 object categories
- 91 stuff categories
- 5 captions per image
- 250,000 people with keypoints

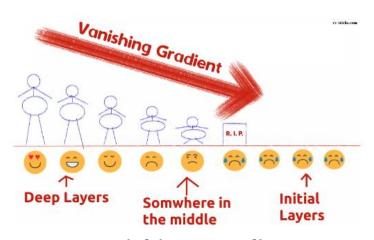
(https://cocodataset.org/#home)

Case 4: ResNet

- Vanishing Gradient
 - 152 Layers (엄청나게 깊은 layer)
 - 기존에는 이렇게 쌓을 생각을 못했을까?
 - 오히려 층을 쌓을수록 어느 순간부터 성능이 감소
 - Why???



(Layer를 더 쌓았는데 training error가 더 높음)

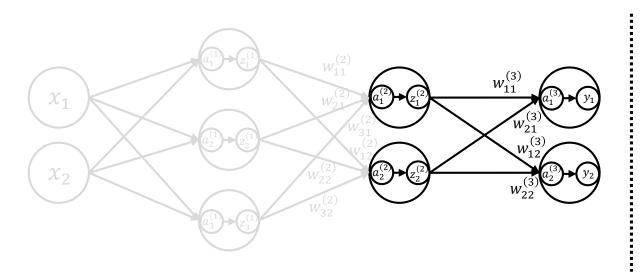


(Vanishing Gradient)

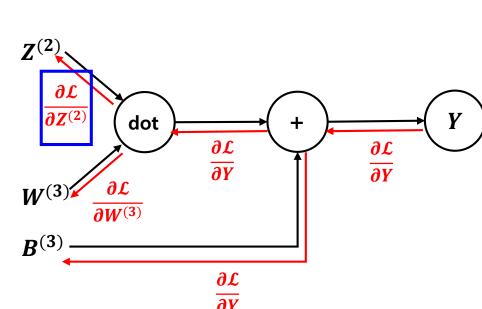
(출처: He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778)., https://wikidocs.net/164800)

CNN in Image Classification: Revisit Backpropagation

• (1) Backpropagation: Output → 2nd hidden layer

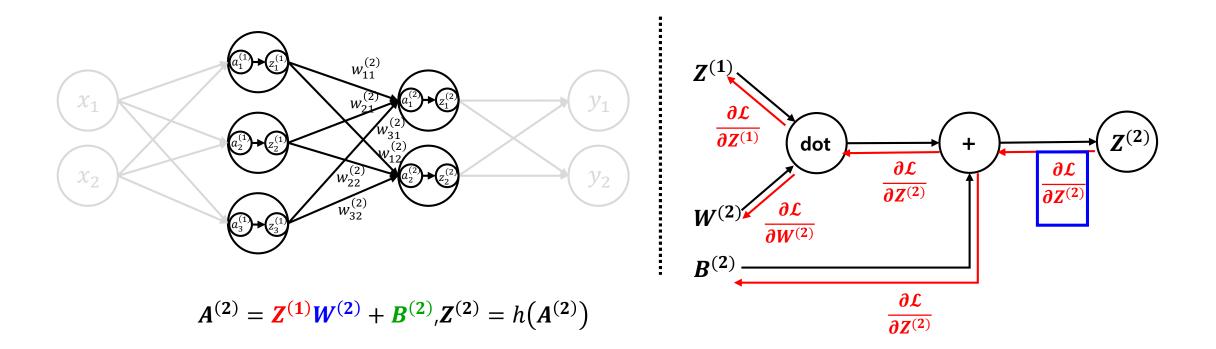


$$A^{(3)} = \mathbf{Z}^{(2)} \mathbf{W}^{(3)} + B^{(3)}, Y = h(A^{(3)})$$



CNN in Image Classification: Revisit Backpropagation

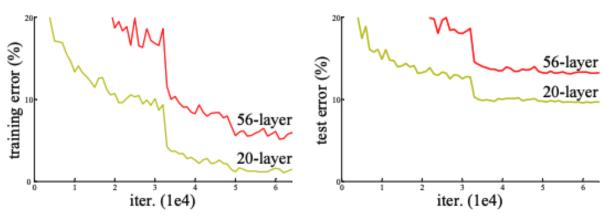
• (2) 2nd hidden layer → 1st hidden layer



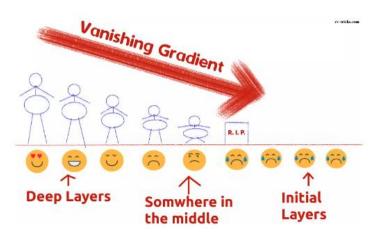
- → 나중 layer에서 계산한 gradient가 이전 layer에서 계산한 gradient에 영향
- → 여기서, (나중 layer, 이전 layer)는 두 layer중에서 각각 (output에 가까운 layer, input에 가까운 layer)를 의미

Case 4: ResNet

- Vanishing Gradient
 - 152 Layers (엄청나게 깊은 layer)
 - 기존에는 이렇게 쌓을 생각을 못했을까?
 - 오히려 층을 쌓을수록 어느 순간부터 성능이 감소
 - Vanishing Gradient: 네트워크의 깊이가 깊어질수록 초기층에 gradient가 전달되지 않아 학습 X



(Layer를 더 쌓았는데 training error가 더 높음)

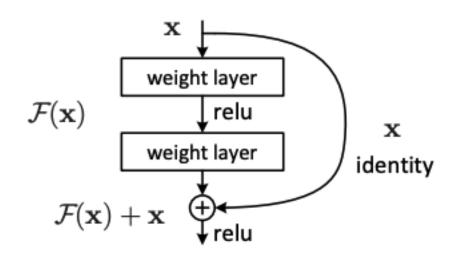


(Vanishing Gradient)

(출처: He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778)., https://wikidocs.net/164800)

Case 4: ResNet

- Residual Block
 - 이런 vanishing gradient를 해결하기 위해 도입한 방법
 - 일정 시점마다 input x자체를 skip connection을 통해 연결
 - Gradient Flow가 원활하게 이루어짐 (모델 깊이에 대한 부담 해소)
 - Fully connected layer제거 (parameter수 감소)

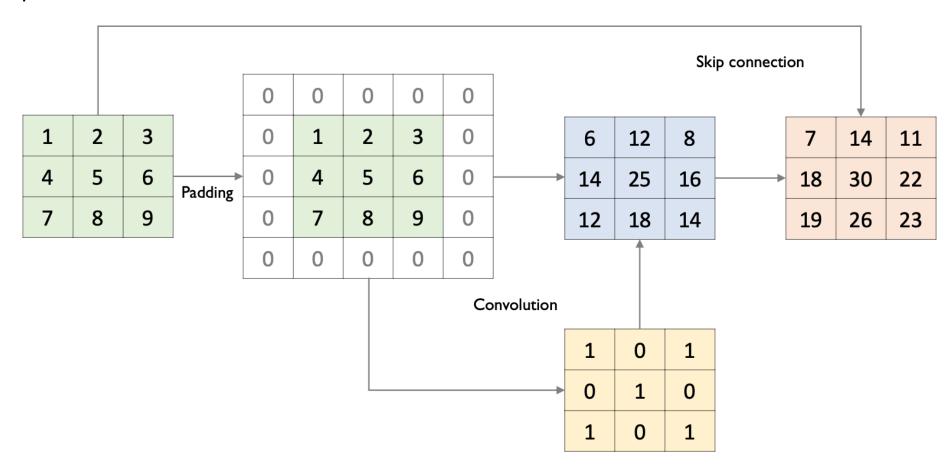


(Residual Block)

(출村: He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778)., https://wikidocs.net/164800)

Case 4: ResNet

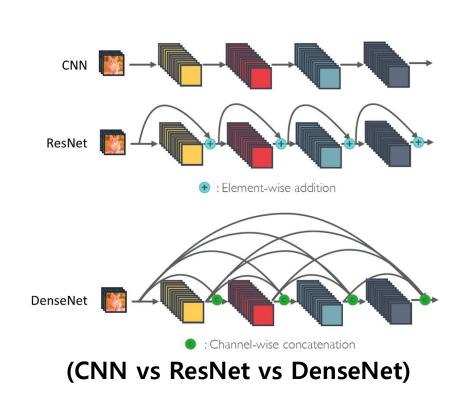
- Skip Connection 예시

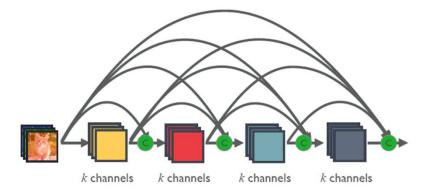


(출처: https://github.com/pilsung-kang/Machine-Learning-Basics-Bflysoft/blob/master/Lecture%207_Deep%20Neural%20Network_CNN.pdf)

Case 5: DenseNet

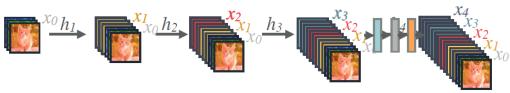
- Skip Connection을 더 늘려보자! → 대신, 정보를 add 하지 말고, concatenate
- 모든 layer를 다 연결하면 param수 급증 → 각 layer의 channel수를 줄임





k: Growth Rate

(각 layer의 channel수를 줄임)

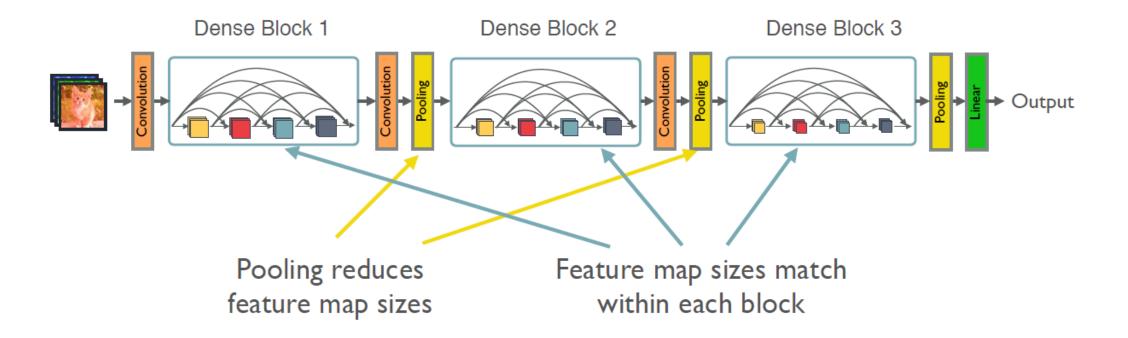


(Forward Propagation)

(출처: https://oi.readthedocs.io/en/latest/computer_vision/cnn/densenet.html)

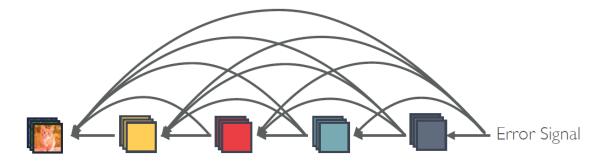
Case 5: DenseNet

- 아무리 그래도, 모든 layer를 다 연결하면 param수가...
- Dense Block내에서 channel concatenate

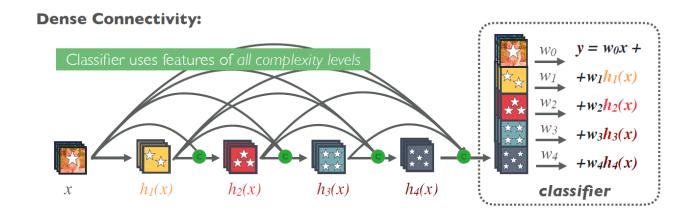


(출처: https://oi.readthedocs.io/en/latest/computer_vision/cnn/densenet.html)

- Case 5: DenseNet
 - DenseNet의 장점(1): Gradient 전달이 잘 이뤄짐



- DenseNet의 장점(2): Low Feature도 반영 가능



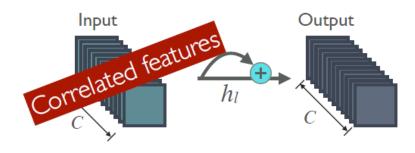
(출처: https://oi.readthedocs.io/en/latest/computer_vision/cnn/densenet.html)

Case 5: DenseNet

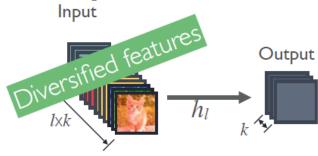
2023-10-06

- DenseNet의 장점(3): Parameter수가 적음

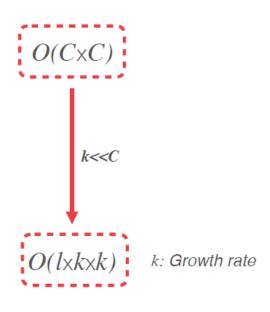
ResNet connectivity:



DenseNet connectivity:



#parameters:



(출처: https://oi.readthedocs.io/en/latest/computer_vision/cnn/densenet.html)

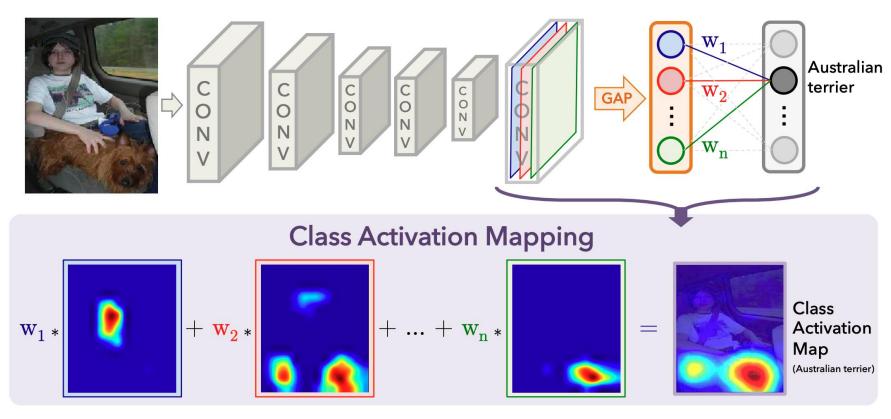
3. Class Activation Map (CAM)

Image Localization

- Class Activation Map (CAM)
 - Convolution layer는 객체의 위치를 알고 있음
 - Fully connected layer를 쓰면 이게 망가짐
 - Classifier로 localization수행
 - Convolution layer만으로 모델을 구성
 - 마지막 feature map을 class수와 동일하게 생성
 - FC layer를 제거하고 global average pooling으로 출력과 mapping
 - Classifier CNN은 이미 localize 정보를 갖고 있음

Image Localization

- Class Activation Map (CAM)
 - Localize Significant areas based only on class label information

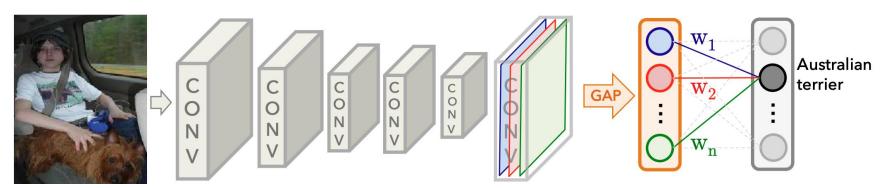


(출처: Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning deep features for discriminative localization. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 2921-2929).)

Image Localization

- Class Activation Map (CAM)
 - $f_k(x,y)$: 마지막 convolution layer unit k의 (x,y) 위치에서의 activation값
 - $F_k = \sum_{x,y} f_k(x,y)$: global average pooling 결과 값
 - $S_c = \sum_k w_k^c F_k$, where w_k^c : 클래스 c에 대해 F_k 의 중요도 $\Rightarrow P_c = \frac{exp(S_c)}{\sum_c exp(S_c)}$
 - $S_c = \sum_k w_k^c F_k = \sum_k w_k^c \sum_{x,y} f_k(x,y) = \sum_{x,y} \sum_k w_k^c f_k(x,y) = \sum_{x,y} M_c(x,y)$

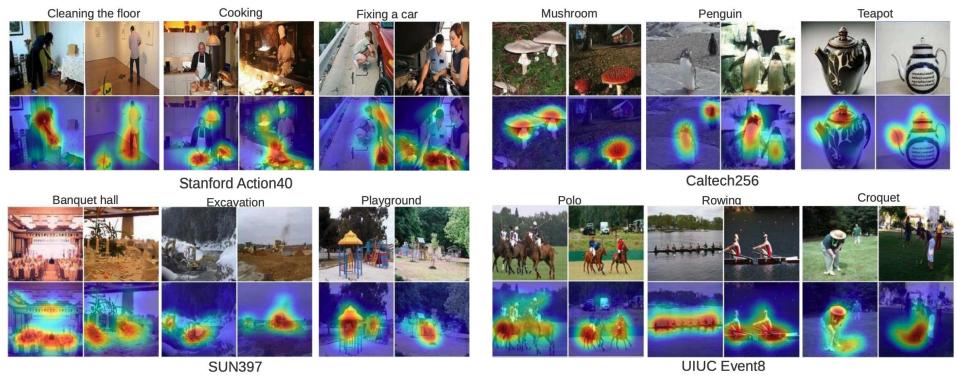
$\rightarrow M_c(x,y)$: (x,y) 위치에서 이미지를 클래스 c로 분류하도록 하는 중요도



(출처: Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning deep features for discriminative localization. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 2921-2929).)

Image Localization

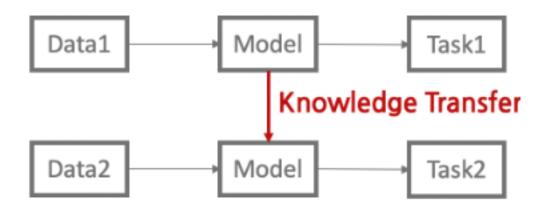
- Class Activation Map (CAM)
 - 특정 class로 분류했을 때, 가장 큰 영향을 끼치는 이미지 영역을 추정



(출처: Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning deep features for discriminative localization. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 2921-2929).)

Transfer Learning

- 특정 task를 학습한 모델을 다른 task 수행에 재사용하는 기법
 - (1) pre-trained model 및 학습 결과(parameter)를 불러오고
 - (2) 우리의 task에 맞도록 모델을 변경/개선
 - (3) 우리의 data를 사용하여 모델을 fine-tuning
- → 대규모 데이터에서 학습한 결과를 기반으로 빠르게 나의 모델을 구축
- → 비교적 적은 데이터로 좋은 결과를 얻을 수 있음



Transfer Learning

- 특정 task를 학습한 모델을 다른 task 수행에 재사용하는 기법

1. Train on Imagenet

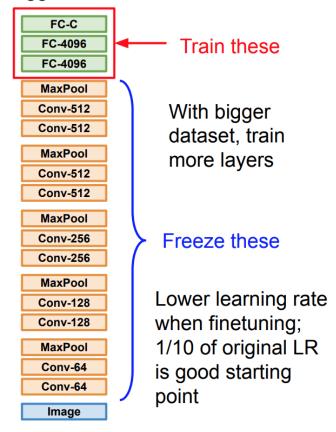
FC-1000 FC-4096 FC-4096 **MaxPool** Conv-512 Conv-512 **MaxPool** Conv-512 Conv-512 **MaxPool** Conv-256 Conv-256 **MaxPool** Conv-128 Conv-128 **MaxPool** Conv-64 Conv-64

Image

2. Small Dataset (C classes)



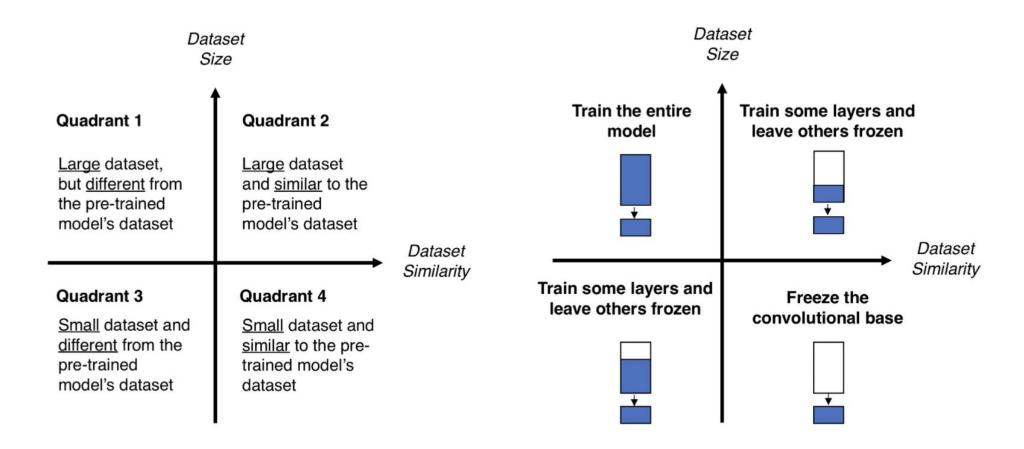
3. Bigger dataset



(출처: Donahue et al, "DeCAF: A Deep Convolutional Activation Feature for Generic Visual Recognition", ICML 2014 Razavian et al, "CNN Features Off-the-Shelf: An Astounding Baseline for Recognition", CVPR Workshops 2014)

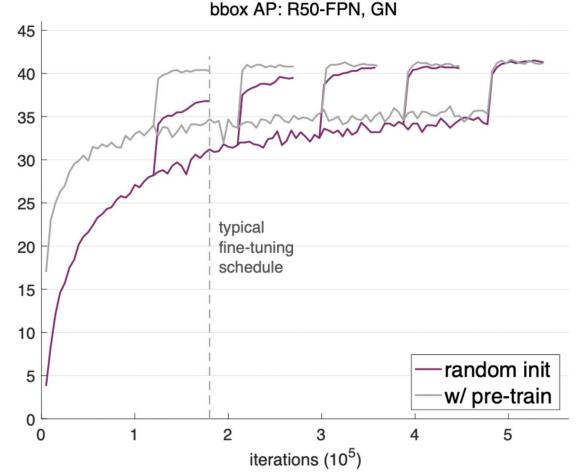
Transfer Learning

- 특정 task를 학습한 모델을 다른 task 수행에 재사용하는 기법



Transfer Learning

- 학습 속도에서 효과가 있음
 - '밑바닥부터' 학습하는 것보다 2~3배 빠름
 - (성능에는 큰 차이가 없다)



(출처: He, K., Girshick, R., & Dollár, P. (2019). Rethinking imagenet pre-training. In Proceedings of the IEEE/CVF International Conference on Computer Vision (pp. 4918-4927).)

Summary

Summary

Advanced CNN Model

- AlexNet: 최초로 conv를 사용. 성능이 괜찮음
- VGG: AlexNet보다 깊은 구조
- GoogleNet: Inception Module을 사용
- ResNet: Skip-connection을 활용하여 gradient vanishing 현상 극복 → 더 깊이!
- DenseNet: 더 많이 connection 생성. Add대신 channel concatenate

Class Activation Map

- Class 정보만으로 중요한 영역을 선정

Transfer Learning

- Pretrained model을 다른 task에 맞도록 모델의 일부만 학습

End of the documents